

doi:10.3969/j.issn.1001-2400.2014.06.001

一种改进的势函数欠定盲源分离算法

付卫红, 王 璐, 马丽芬

(西安电子科技大学 综合业务网理论及关键技术国家重点实验室, 陕西 西安 710071)

摘要: 针对原有的拉普拉斯混合模型势函数法复杂度高、随机选取部分观测数据点作为初始聚类中心的算法聚类结果不稳定、准确率低的问题, 提出了一种改进的势函数欠定盲源分离算法. 该算法在基于密度概念的基础上, 以簇内距离小、簇间距离大为原则, 选取部分高密度点作为势函数的初始聚类中心. 理论分析与仿真实验表明, 改进算法的复杂度大大降低, 而估计准确度降低很少. 在信噪比为 10 dB 时, 该算法仿真时间降为原始势函数法的 5%; 相对随机选取算法, 在计算复杂度基本一致的前提下, 该算法的估计准确度大大提高, 源信号个数估计准确率由 61% 提高到 85%, 混合矩阵估计误差由 0.47 下降为 0.27.

关键词: 欠定盲源分离; 混合矩阵估计; 势函数法; 密度法; 初始聚类中心

中图分类号: TN911.4 **文献标识码:** A **文章编号:** 1001-2400(2014)06-0001-05

Improved laplace mixed model potential function algorithm for UBSS

FU Weihong, WANG Lu, MA Lifan

(State Key Lab. of Integrated Service Networks, Xidian Univ., Xi'an 710071, China)

Abstract: Aiming at the problem that the original Laplace Mixed Model Potential Function (LMMPF) algorithm has high complexity and the random initial cluster center algorithm has a low accuracy and stability, we propose an improved LMMPF algorithm. Based on the concept of density, we can choose some high-density data as the initial cluster centers. These data obey the principle that the distance between the data in the same group is small and the distance between groups is great. Theoretical analysis and experimental results show that compared to the original LMMPF algorithm the complexity of the new algorithm becomes much lower while the estimated accuracy is reduced only a little bit. When the Signal to Noise Ratio (SNR) is 10 dB, the running time of the improved algorithm is reduced to 5%. Compared to the randomly-chosen algorithm, the new algorithm has a much higher accuracy; the accuracy rate of estimating the number of sources is raised from 61% to 85% and the mixing matrix estimated error is reduced from 0.47 to 0.27.

Key Words: underdetermined blind source separation (UBSS); mixing matrix estimation; Laplace mixed model potential function (LMMPF); density; initial clustering centers

盲源分离是指在源信号和传输信道未知的情况下, 仅仅根据感知器接收到的观测信号来分离出混合在一起的源信号. 盲分离技术可广泛用于生物医学工程、语音通信、图像处理、遥感等领域中, 因此盲分离成了现代信号处理领域研究的热点问题^[1-3].

在实际问题中, 源信号的个数往往大于观测信号的个数, 此时即为欠定情况. 目前欠定盲源分离算法的理论主要建立在稀疏分量分析上, 采取“两步法”求解: ①利用稀疏混合信号的聚类特性估计出混合矩阵; ②利用

收稿日期: 2013-08-26

网络出版时间: 2014-04-04

基金项目: 国家自然科学基金资助项目 (61201134, 61201135); 中央高校基本科研业务费专项资金资助项目 (72124669); 高等学校学科创新引智计划资助项目 (B08038); 重大专项基金资助项目 (2012ZX03001027-001)

作者简介: 付卫红 (1979-), 女, 副教授, 博士, E-mail: whfu@mail.xidian.edu.cn.

网络出版地址: <http://www.cnki.net/kcms/doi/10.3969/j.issn.1001-2400.2014.06.001.html>

混合矩阵的估计值来恢复出源信号. 目前充分稀疏信号盲源分离时估计混合矩阵的常用方法有: K 均值聚类法^[4-6]、模糊 C 均值(Fuzzy C-Means, FCM)聚类算法^[7]、拉普拉斯势函数法^[8]等. 文献[4-7]所提方法需已知源信号个数, 且传统的 K 均值聚类估计精度不高, 鲁棒性不好, 而文献[8]中拉普拉斯势函数法计算量太大. 为减少计算量, 提高算法的鲁棒性, 文献[9]提出了基于 K 均值聚类的势函数法. 该方法是在传统的 K 均值聚类后, 再结合势函数法来提高估计精度, 因此仍需要已知源信号个数. 针对欠定盲源分离问题, 笔者提出一种改进的势函数算法, 该算法通过计算观测数据各点的密度, 选取部分高密度点作为势函数的初始聚类中心, 与原势函数法相比, 该算法复杂度显著降低, 而估计准确度却降低很少, 同时无需预知源信号个数.

1 稀疏欠定盲分离模型

信号稀疏是指源信号在绝大多数采样点的取值为零或接近零, 只有少数采样点的取值远离零. 以信号稀疏为前提, Georgiev 等提出了稀疏分量分析在盲源分离中可以完全重构源信号的两个条件^[10]:

- (1) 混合矩阵 $A \in \mathbf{R}^{m \times n}$ 的任意 $m \times m$ 的子矩阵都是非奇异的, 其中, m 为观测信号个数, n 为源信号个数.
- (2) 源信号的任何采样时刻 $s(t)$ 最多只有 $m-1$ 个非零元素.

欠定盲分离的混合模型可以表示为

$$\mathbf{x}(t) = \mathbf{A}\mathbf{s}(t) + \mathbf{v}(t), \quad t = 1, 2, \dots, T, \quad (1)$$

其中, $\mathbf{x}(t) = [x_1(t), x_2(t), \dots, x_m(t)]^T$, 为 t 时刻的观测信号矢量; \mathbf{A} 为 $m \times n$ 的矩阵; $\mathbf{s}(t) = [s_1(t), s_2(t), \dots, s_n(t)]^T$, 为 t 时刻源信号矢量; $\mathbf{v}(t) = [v_1(t), v_2(t), \dots, v_m(t)]^T$, 为 t 时刻高斯白噪声; T 为采样点数. 为了描述方便, 式(1)可改写为

$$\mathbf{x}(t) = \sum_{i=1}^n \mathbf{a}_i s_i(t) + \mathbf{v}(t), \quad (2)$$

其中, $\mathbf{a}_i = [a_{1i}, a_{2i}, \dots, a_{mi}]^T$, 为混合矩阵 \mathbf{A} 的第 i 列矢量. 当源信号稀疏时, 在同一时刻一般只有一个源信号的取值比较大, 其余源信号的取值近似为零. 如假设在 t 时刻只有 s_1 单独作用, 则式(2)为 $\mathbf{x}(t) = \mathbf{a}_1 s_1(t) + \mathbf{v}(t)$. 可见, 若无噪声, 观测数据 $\mathbf{x}(t)$ 将分布在 m 维混合信号空间中一条经过原点的直线上, 直线的方向取决于混合矩阵的列矢量 \mathbf{a}_i . 当噪声较小且源信号稀疏时, 观测数据主要分布在若干条直线附近, 这些直线的方向与对应的混合矩阵的列矢量方向相同, 即稀疏信号具有线性聚类的特征^[8].

2 改进的势函数欠定盲分离算法

由上述分析可知, 稀疏信号盲源分离时, 对混合矩阵的估计可归结为对观测信号散点图的直线方向进行聚类. 为了减少噪声的影响和计算量, 先将观测数据矩阵 \mathbf{X} 中的列矢量 $\mathbf{x}(t)$ 进行如下处理:

$$\mathbf{x}(t) = \begin{cases} \mathbf{x}(t), & \|\mathbf{x}(t)\|_2 \geq \varepsilon_1 \\ 0, & \|\mathbf{x}(t)\|_2 < \varepsilon_1 \end{cases}, \quad t = 1, 2, \dots, T, \quad (3)$$

其中, T 为采样点数; $\|\cdot\|_2$ 为 l_2 范数; ε_1 为设定的低能量点的门限值, 可通过观察散点图凭经验选取, 这里取 $\varepsilon_1 = 0.2$. 为便于操作, 将经过式(13)处理后的 \mathbf{X} 中为零的列去除, 得到新的观测数据矩阵 \mathbf{X}' , 将 \mathbf{X}' 中的列向量 $\mathbf{x}'(t)$ 按式(4)标准化为 $\bar{\mathbf{x}}(t)$, 即

$$\bar{\mathbf{x}}(t) = \text{sign}(x'_m(t)) \cdot \mathbf{x}'(t) / \|\mathbf{x}'(t)\|_2, \quad t = 1, 2, \dots, T_1, \quad (4)$$

其中, $\text{sign}(x)$ 为符号函数; 当 x 为非负时, 取值为 1; 否则, 为 -1. $x'_m(t)$ 为 $\mathbf{x}'(t)$ 的最后一个分量; T_1 为 \mathbf{X}' 的列数. 这样, 具有线性分布的观测信号将在上半球面上按拉普拉斯概率分布在各个聚类中心点附近. 为得到更高效的聚类过程, 笔者对势函数法进行了改进, 提出了基于密度来选取势函数初始聚类中心的方法.

2.1 基于密度选取初始聚类中心的基本思想

定义 1 任意两个数据点间的欧氏距离为

$$d(\mathbf{x}(i), \mathbf{x}(j)) = (|x_1(i) - x_1(j)|^2 + |x_2(i) - x_2(j)|^2 + \dots + |x_m(i) - x_m(j)|^2)^{1/2}, \quad (5)$$

<http://www.xdxb.net>

其中, $\mathbf{x}(i) = [x_1(i), x_2(i), \dots, x_m(i)]^T$ 和 $\mathbf{x}(j) = [x_1(j), x_2(j), \dots, x_m(j)]^T$, 为两个 m 维数据点.

定义 2 L 个数据点间的平均距离为

$$D_M = \sum_{i=1}^L \sum_{j=1}^L d(\mathbf{x}(i), \mathbf{x}(j)) / (L(L-1)) \quad (6)$$

定义 3 数据点的密度参数. 空间中任一点 $\mathbf{x}(i)$, 以该点为中心, 半径为 R 的区域称为该点的邻域, 邻域内的点的个数称为点 $\mathbf{x}(i)$ 基于距离 R 的密度参数, 这里取 $R = D_M$, 则点 $\mathbf{x}(i)$ 的密度参数 $D(\mathbf{x}(i))$ 可表示为

$$D(\mathbf{x}(i)) = \sum_{j=1}^L u(D_M - d(\mathbf{x}(i), \mathbf{x}(j))) \quad , \quad \text{其中}, u(x) = \begin{cases} 1 & , x \geq 0 \\ 0 & , \text{其他} \end{cases} \quad (7)$$

空间中任意一点 $\mathbf{x}(i)$, 若其附近的点越多, 则 $D(\mathbf{x}(i))$ 越大. 故选择 $D(\mathbf{x}(i))$ 大的点作为初始聚类中心, 有利于聚类过程的高效收敛. 同时, 为了避免所选的初始聚类中心局部收敛, 在选取初始聚类中心时, 尽可能使所选点之间的距离最大^[5]. 因此, 基于密度选取初始聚类中心算法的具体步骤如下:

(1) 按式(3)和式(4)对观测信号 $\mathbf{x}(t)$ 预处理, 得到 $\bar{\mathbf{x}}(t)$.

(2) 按式(5)~(7)计算 t 时刻观测数据点 $\bar{\mathbf{x}}(t)$ 的密度参数 $D(\bar{\mathbf{x}}(t))$, 选取出满足 $D(\bar{\mathbf{x}}(t)) > \epsilon_2 \max_{t=1,2,\dots,T_1} D(\bar{\mathbf{x}}(t))$ 的 $\bar{\mathbf{x}}(t)$, 记为 $\tilde{\mathbf{x}}(t)$, 放入高密度点集合 H 中. 为降低算法复杂度以及减少噪声的影响, 可选取满足 $D(\bar{\mathbf{x}}(t)) > \epsilon_3 \max_{t=1,2,\dots,T_1} D(\bar{\mathbf{x}}(t))$ 的 $\bar{\mathbf{x}}(t)$, 记为 $\hat{\mathbf{x}}(t)$, 按列存放于矩阵 \hat{X} 中, 作为处理后的观测数据, 其中, ϵ_2 和 ϵ_3 满足 $0 < \epsilon_3 < \epsilon_2 < 0.5$, 这里取 $\epsilon_2 = 0.35, \epsilon_3 = 0.1$.

(3) 在 H 中选择密度参数值最大的数据点作为第 1 个初始聚类中心, 记为 \mathbf{z}_1 , 取 H 中距离 \mathbf{z}_1 最远的数据点作为第 2 个聚类中心 \mathbf{z}_2 , 将 \mathbf{z}_1 和 \mathbf{z}_2 按列存放于初始聚类中心矩阵 Z 中, 并在 H 中将 \mathbf{z}_1 和 \mathbf{z}_2 删除.

(4) 计算 H 中剩余的数据点 $\tilde{\mathbf{x}}(t)$ 到已选的初始聚类中心 $\{\mathbf{z}_h\}$ 的距离 $d(\tilde{\mathbf{x}}(t), \mathbf{z}_h)$ ($h=1, 2$).

(5) \mathbf{z}_3 为 H 中满足 $\max(\min(d(\tilde{\mathbf{x}}(t), \mathbf{z}_1), d(\tilde{\mathbf{x}}(t), \mathbf{z}_2)))$ 的 $\tilde{\mathbf{x}}(t)$, 将 \mathbf{z}_3 并入 Z 中, 并在 H 中将 \mathbf{z}_3 删除, 同

理, \mathbf{z}_k 为 H 中满足 $\max(\min(d(\tilde{\mathbf{x}}(t), \mathbf{z}_1), d(\tilde{\mathbf{x}}(t), \mathbf{z}_2), \dots, d(\tilde{\mathbf{x}}(t), \mathbf{z}_{k-1})))$ 的 $\tilde{\mathbf{x}}(t)$, 如此循环, 直至找出 C 个初始聚类中心, C 的值可按 $T \gg C > m$ (T 为采样点数, m 为观测信号个数) 来选取, 这里取 $C = 5m$.

2.2 改进的势函数欠定盲分离算法步骤

2.1 节中基于密度选取初始聚类中心的方法可用于势函数, 来解决源信号个数未知的欠定盲分离问题. 为了正确估计势函数的各个局部最大值, 可采用拉普拉斯全局相似测试函数, 即

$$J(\mathbf{o}_k)_\gamma = \sum_{t=1}^{T_2} \left(\exp(-\|\hat{\mathbf{x}}(t) - \mathbf{o}_k\|_2^2 / b) \right)^\gamma \quad , \quad k=1, 2, \dots, C \quad (8)$$

其中, $\hat{\mathbf{x}}(t)$ 为 2.1 节中得到的处理后的观测数据矩阵 \hat{X} 中的列矢量, T_2 为 \hat{X} 的列数. 当 $J(\mathbf{o}_k)_\gamma$ 取得局部最大值时, 所对应的 \mathbf{o}_k 可近似作为观测数据的聚类中心. 式(8)中参数 b 的值可用下式估计:

$$b = \frac{1}{T_2} \sum_{t=1}^{T_2} \|\hat{\mathbf{x}}(t) - \mu\|_2^2 \quad , \quad \text{其中}, \mu = \frac{1}{T_2} \sum_{t=1}^{T_2} \hat{\mathbf{x}}(t) \quad (9)$$

为选取合适的 γ 值, 将式(8)改写为

$$J(\hat{\mathbf{x}}(r))_{\gamma_i} = \sum_{t=1}^{T_2} \left(\exp(-\|\hat{\mathbf{x}}(t) - \hat{\mathbf{x}}(r)\|_2^2 / b) \right)^{\gamma_i} \quad , \quad r=1, 2, \dots, T_2 \quad (10)$$

其中, $\hat{\mathbf{x}}(t)$ 与 $\hat{\mathbf{x}}(r)$ 均为 2.1 节中得到的处理后的观测信号矩阵 \hat{X} 的列矢量.

可用相关比较算法^[11]来估计参数 γ , 令 $\gamma_i = 5i$ ($i=1, 2, \dots$); ①初始时, $i=1, \epsilon' = 0.98$; ②令 $\mathbf{w} = [J(\hat{\mathbf{x}}(1))_{\gamma_i}, J(\hat{\mathbf{x}}(2))_{\gamma_i}, \dots, J(\hat{\mathbf{x}}(T_2))_{\gamma_i}]$, $\mathbf{v} = [J(\hat{\mathbf{x}}(1))_{\gamma_{i+1}}, J(\hat{\mathbf{x}}(2))_{\gamma_{i+1}}, \dots, J(\hat{\mathbf{x}}(T_2))_{\gamma_{i+1}}]$, 计算 \mathbf{w} 和 \mathbf{v} 的相关系数 η_i ; ③若 $\eta_i \geq \epsilon'$, 则取 γ_i 作为 γ 的估计值, 即 $\gamma = \gamma_i$; 否则, $i = i + 1$, 返回②.

选取合适的参数值后, 要求解 $J(\mathbf{o}_k)_\gamma$ 的极大值可以先求导 $\partial J(\mathbf{o}_k)_\gamma / \partial \mathbf{o}_k$, 令导数值为 0, 然后采用固定点优化迭代算法^[8], 得到第 $l+1$ 次迭代时第 k 个聚类中心 \mathbf{o}_k^{l+1} 的表达式, 即

<http://www.xdxb.net>

$$\mathbf{o}_k^{l+1} = \sum_{t=1}^{T_2} \hat{\mathbf{x}}(t) \exp\left(-\|\hat{\mathbf{x}}(t) - \mathbf{o}_k^l\|_2^2/b\right)^\gamma / \sum_{t=1}^{T_2} \exp\left(-\|\hat{\mathbf{x}}(t) - \mathbf{o}_k^l\|_2^2/b\right)^\gamma, \quad (11)$$

其中, l 为迭代次数, l 的初始取值为 0, 并令 $\mathbf{o}_k^0 = \mathbf{z}_k, k=1, 2, \dots, C, \mathbf{z}_k$ 为 2.1 节中所得初始聚类中心矩阵 Z 中的列矢量. 当 $\max_{k=1, 2, \dots, C} \|\mathbf{o}_k^{l+1} - \mathbf{o}_k^l\|_2 < \varepsilon_4$ 时, 停止迭代. 其中, ε_4 为计算精度, 其越接近 0, 精度越高, 但算法的复杂度也增加, 这里取 $\varepsilon_4 = 10^{-6}$.

当算法收敛后, 聚类中心矢量 \mathbf{o}_k 将凝聚在 $J(\mathbf{o}_k)_\gamma$ 的各个局部最大值处. 而在实际中, $J(\mathbf{o}_k)_\gamma$ 的有些局部最大值是由噪声和异常值造成的, 但噪声和异常值所产生的聚类中心对应的 $J(\mathbf{o}_k)_\gamma$ 值相对来说较小, 故可按

$$J(\mathbf{o}_k)_\gamma / \max_{k=1, 2, \dots, C} (J(\mathbf{o}_k)_\gamma) > \varepsilon_5 \quad (12)$$

来消除噪声和异常值的影响^[8], 将不满足式(12)的 \mathbf{o}_k 剔除, 最终保留下来的聚类中心个数即源信号的个数, 聚类中心矢量即估计的混合矩阵的列矢量. ε_5 的大小可凭经验选取, 这里取 $\varepsilon_5 = 0.5$.

经过上述分析和说明, 文中改进的势函数欠定盲分离算法步骤可总结如下:

(1) 按 2.1 节中初始聚类中心, 选取算法的步骤(1)~(5), 得到初始聚类中心矩阵 Z 和处理后的观测数据矩阵 \hat{X} .

(2) 利用式(9)及相关比较算法分别估计参数 b 和 γ .

(3) 迭代初始化, 令初始迭代次数 $l=0, \mathbf{o}_k^0 = \mathbf{z}_k (k=1, 2, \dots, C), \mathbf{z}_k$ 为 Z 的列矢量.

(4) 按式(11)计算第 k 个聚类中心第 $l+1$ 次的迭代值 $\mathbf{o}_k^{l+1} (k=1, 2, \dots, C)$, 对其归一化.

(5) 若 $\max_{k=1, 2, \dots, C} \|\mathbf{o}_k^{l+1} - \mathbf{o}_k^l\|_2 < \varepsilon_4$, 则停止迭代, $\mathbf{o}_k = \mathbf{o}_k^{l+1}$; 否则, $l=l+1$, 返回步骤(4).

(6) 将 \mathbf{o}_k 代入式(12), 选出满足式(12)的聚类中心矢量 \mathbf{o}_k , 将选出的 \mathbf{o}_k 按列排列, 组成的矩阵即混合矩阵的估计值 \hat{A} , \hat{A} 的列数即为源信号的个数.

2.3 算法复杂度分析

原有势函数法, 如文献[8]中拉普拉斯混合模型势函数(LMMPF)算法, 将所有观测数据作为初始聚类中心, 为达到最佳的聚类结果, 所有聚类中心将不断迭代, 每迭代 1 次的计算量为 $O(T^2m)$, 其中, m 为观测信号个数, T 为观测数据点数. 而文中算法在保证准确稳定估计混合矩阵的前提下, 将初始聚类中心的个数减少为 C , 所有聚类中心每迭代 1 次的计算量降为 $O(C^2m)$, $C \ll T$. 尽管附加的密度法会给算法带来额外的计算量, 但相对于聚类中心的迭代可以忽略. 此外, 由于密度法选取的初始聚类中心更接近于最终的聚类中心, 因此聚类中心迭代次数将减少. 故文中改进的势函数法大大减少了算法的复杂度, 提高了估计的实时性.

3 算法仿真及分析

为验证文中算法的有效性, 定义混合矩阵的估计误差 $\varepsilon = \|\hat{A}P - A\|_F$, 其中, $\|\cdot\|_F$ 为 F 范数; \hat{A} 为混合矩阵 A 的估计值; P 为置换矩阵, 用于调整 \hat{A} 的顺序. 源信号由计算机模拟产生, 即

$$S = -\log\left(\text{rand}(n, T) \max\left(0, \text{sign}(\text{rand}(n, T) - p)\right)\right), \quad 0 \leq p \leq 1,$$

其中, n 为源信号个数; T 为数据长度; p 为稀疏度因子, p 值越大, 信号的稀疏度越高. 这里取 $T=2000, p=0.9$, 观测信号个数 $m=3$, 源信号个数 $n=5$, 实验次数为 1000 次, 在混合信号中加入高斯白噪声, 信噪比范围为 10~20 dB, 混合矩阵 A 选取如下:

$$A = \begin{bmatrix} 0.5525 & -0.1904 & 0.5707 & 0.7240 & -0.0759 \\ 0.6863 & 0.5148 & -0.5166 & 0.4088 & -0.8293 \\ 0.4730 & 0.8459 & 0.6383 & -0.5556 & 0.5536 \end{bmatrix}.$$

从算法仿真运行时间、源信号个数估计正确率、混合矩阵估计误差以及稀疏度对算法性能的影响, 对文中改进算法、原始 LMMPF 法以及随机选取初始聚类中心算法进行比较. 图 1~图 3 分别为信噪比不同时, 3 种算法源信号个数估计的正确率、混合矩阵估计误差和仿真运行时间对比结果. 图 4~图 6 是信噪比为 25 dB, 稀疏度为 0.70~0.95, 其他参数同上的情况下, 3 种算法仿真时间、源信号个数估计正确率和混合矩

阵估计误差的对比结果。




图1 不同信噪比下源信号个数估计正确率




图2 不同信噪比下混合矩阵估计误差




图3 不同信噪比下算法运行时间




图4 不同稀疏度下算法运行时间




图5 不同稀疏度下源信号个数估计正确率




图6 不同稀疏度下混合矩阵估计误差

由图1和图2可知,文中改进算法估计稳定,准确率与原始势函数法很接近,且比随机选取初始聚类中心算法正确率高,估计误差小。在信噪比为10 dB时,源信号个数估计准确率由随机选取算法的61%提高到85%,混合矩阵估计误差由0.47下降为0.27。图3和图4表明,文中改进算法与原始势函数法相比,算法复杂度大大降低,尤其在信噪比为10 dB时,文中改进算法的仿真运行时间仅为原始LMMPF的5%。

由图5和图6可知,该算法在信噪比为25 dB时,对源信号的稀疏度要求并不高,信号稀疏度仅为0.75时,源信号个数估计准确率可达99%,混合矩阵估计误差也小于0.0815。

4 总 结

笔者提出的改进的势函数欠定盲分离算法能够在源信号个数未知的情况下,快速、准确、稳定地解决欠定盲源分离问题。与原始的势函数法相比,在信噪比为10 dB时,每仿真一次所需时间仅为原始LMMPF的5%,算法复杂度大大降低,而估计准确度降低很少。相对随机选取算法,在计算复杂度基本一致的前提下,笔者所提算法的估计准确度大大提高,当信噪比为10 dB时,源信号个数估计准确率由61%提高到85%,混合

(下转第88页)

1507.

Lian Ke, Huang Jianguo, Wang Houjun, et al. Study on a GA-Based SVM Decision-tree Multi-Classification Strategy [J]. Acta Electronica Sinica, 2008, 36(8): 1502-1507.

[11] Birbil S T, Fang S C. An Electromagnetism-like Mechanism for Global Optimization [J]. Journal of Global Optimization, 2003, 25(3): 263-282.

[12] 姜建国, 龙秀萍, 田旻, 等. 一种基于佳点集类电磁机制算法[J]. 西安电子科技大学学报, 2011, 38(6): 167-172.
Jiang Jianguo, Long Xiuping, Tian Min, et al. Electromagnetism-like Mechanism Algorithm Based on the Good Point Set[J]. Journal of Xidian University, 2011, 38(6): 167-172.

(编辑: 郭 华)

(上接第 5 页)

矩阵估计误差由 0.47 下降为 0.27. 此外, 该算法在信噪比较高时(如 25 dB), 对源信号的稀疏度要求并不高, 当信号稀疏度为 0.75 时, 源信号个数估计准确率可达 99%, 混合矩阵估计误差也小于 0.0815.

参考文献:

- [1] Yao Bo, Yang Jihai, Chen Xiang. Underdetermined Blind Source Separation Based on Sparse Component Analysis Applied in Decomposition of Surface Electromyography[J]. Sparse Medicine & Medical Engineering, 2012, 25(2): 107-111.
- [2] Thiagarajan J J, Ramamurthy N R, Spanias A. Mixing Matrix Estimation Using Discriminative Clustering for Blind Source Separation[J]. Digital Signal Processing, 2013, 23(1): 9-18.
- [3] Wang R J, Zhan Y J, Zhou H F. A Method of Underdetermined Blind Source Separation in Time-domain [J]. International Journal of Electronics, 2012, 99(4): 543-555.
- [4] 赵恒, 杨万海, 张高煜. 模糊 K-Harmonic Means 聚类算法[J]. 西安电子科技大学学报, 2005, 32(4): 603-607.
Zhao Heng, Yang Wanhai, Zhang Gaoyu. Fuzzy K-Harmonic Means Clustering Algorithm [J]. Journal of Xidian University, 2005, 32(4): 603-607.
- [5] 熊忠阳, 陈若田, 张玉芳. 一种有效的 K-means 聚类中心初始化方法[J]. 计算机应用研究, 2011, 11(50): 4189-4190.
Xiong Zhongyang, Chen Ruotian, Zhang Yufang. Effective Method for Cluster Centers' Initialization in K-means Clustering [J]. Application Research of Computers, 2011, 11(50): 4189-4190.
- [6] Huang Min, He Zhongshi, Xing Xinlai, et al. New K-means Clustering Center Select Algorithm [J]. Computer Engineering and Applications, 2011, 47(35): 132-134.
- [7] Chiu S L. Fuzzy Model Identification Based on Cluster Estimation [C]//IEEE International Conference on Fuzzy Systems; 2. Piscataway: IEEE, 1994: 267-278.
- [8] 张焱, 方勇. 基于拉普拉斯势函数的欠定盲分离中源数的估计[J]. 信号处理, 2009, 25(11): 1719-1725.
Zhang Ye, Fang Yong. A New Method to Estimate the Number of the Sources for Underdetermined Blind Separation Based on Lapulacial Potential Function[J]. Signal Processing, 2009, 25(11): 1719-1725.
- [9] 杨静, 张玉洁, 李宏伟. 基于 K-均值聚类和势函数法的欠定盲分离[J]. 电信科学, 2012, 1(1): 98-101.
Yang Jing, Zhang Yujie, Li Hongwei. Underdetermined Blind Source Separation Alogrithm Based on K-means Clustering and Potential Function[J]. Telecommunications Science, 2012, 1(1): 98-101.
- [10] Georgiev P, Theis F J, Cichocki A. Sparse Component Analysis and Blind Source Separation of Underdeterminind Mixtures[J]. IEEE Transactions on Neural Networks, 2005, 16(4): 992-996.
- [11] Yang M S, Wu K L. A Similarity-based Robust Clustering Method [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2004, 26(4): 434-448.

(编辑: 齐淑娟)

<http://www.xdxj.net>